

반도체 인공지능 모델링 및 응용실습

- AI 핵심 개념과 문제정의 프레임워크 -

성균관대학교 반도체융합공학과
김원식

강 의 계 획 서

학년도/학기	2026년도/1학기	학수번호-분반	SEE5012	이수구분	전공
교과목명	반도체 특성화 인공지능 모델링 및 응용 실습			성명	김원식
수강대상학과	반도체융합공학과				
선이수과목 (권장)	반도체융합공학개론(SEE5005)				

수업 내용		수업 핵심질문 (핵심 개념)
1주차	OT, 환경 설정, 문제 정의	수업 목표, 프로그램설치
2주차	파이썬 기초 문법 ①	변수, 자료형, 조건문, 반복문
3주차	파이썬 기초 문법 ② & 함수	리스트, 딕셔너리, 함수 정의
4주차	Numpy & Pandas로 반도체 수율 데이터 다루기	Numpy 배열 기초
5주차	회귀 기본 & 선형회귀로 수율 예측	지도학습, 회귀 개념
6주차	분류 기본 & 불량 분류 (랜덤포레스트 사용)	회귀 vs 분류
7주차	Feature Engineering 기초 (간단 버전)	스케일링 개념
8주차	간단한 모델 비교 & 정리	교차검증 개념 간단 소개
9주차	딥러닝 개념 & PyTorch 준비	뉴런, 레이어, MLP 구조 개념
10주차	단일 MLP 모델로 수율 예측 ①	하나의 고정된 MLP 구조 설계
11주차	MLP 모델 개선 (아주 최소한만)	과적합 개념
12주차	프로젝트 준비: 데이터 분석 & 베이스라인 확정	관심 특성 선택
13주차	새로운 변수 설계 & ML 모델 재학습	도메인 지식에 기반한 파생 변수 2-3개 설계
14주차	MLP에 새 변수 반영 & 모델 비교	입력 자원만 바뀌어 MLP 다시 학습
15주차	결과 정리 & 짧은 리포트 초안	결과 해석을 위한 간단한 틀
16주차	최종 발표 & 피드백	팀/개인별 10분 내외 발표

과제물								
평가 요소	출석	과제/토론	중간시험	기말시험	평소학습	발표	기타	합계
	40%	20%	20%	20%				100%
평가 방법	출석/과제/시험 결과를 토대로 절대평가							

강의 목표

2025년 6월: 수강생 AI 비전문가 최고 수준 활용

2025년 9월: 수강생 학위 논문에 AI 활용 포함


2025년 12월: LLM 활용 아니고 전문 분야 활용하는 법 설명할 수 있는 정도만

2026년 2월: AI에서 하드웨어 중요성과 소프트웨어 중요성 이해하기

여러분은 ?

과제~ 5주차까지 본인의 해석/분석하려는 데이터 준비 및 발표
발표: 기말까지 AI 활용하여 얻고 싶은 결과에 대해 1 슬라이드 작성
(4월 23일)

AI, ML, DL의 차이



AI는 기계가 인간처럼 똑똑하게 문제를 해결하도록 만드는 모든 기술
머신러닝은 데이터로부터 학습하는 방법에 집중
딥러닝은 머신러닝 안에 포함되는 방법 중 하나로, 인공신경망을 여러 층으로 깊게 쌓아 복잡한 패턴을 학습

AI와 자동화 시스템

자동화 시스템 (Automation)

미리 설정된 규칙(Rule)에 따라 반복적인 작업을 수행하는 기술
A 상황이 발생하면 B를 하라는 명확한 명령어가 입력되어 있어야 작동
작동 방식: 'If-Then' 논리 (만약 ~하면, ~하라).



인공지능 (AI)

데이터를 통해 스스로 학습(Learning)하고, 복잡한 상황에서 최선의 의사결정을 내리는 기술. 명시적인 프로그래밍 없이도 패턴을 찾아내어 예측
데이터 분석 및 패턴 인식 (머신러닝/딥러닝).
새로운 데이터를 접할수록 성능이 향상되며, 모호한 상황에서도 확률적인 판단

구분	자동화 (Automation)	인공지능 (AI)
주요 목적	효율성과 반복성 극대화	인간의 지능 모방 및 문제 해결
지능 수준	지능 없음 (수동적 명령 수행)	지능 있음 (능동적 판단 및 학습)
적응성	변화에 취약함 (재설정 필요)	변화에 적응함 (학습을 통해 개선)
결과물	항상 동일한 결과	상황에 따른 최적의 결과

왜 완벽한 자동화시스템 대신 인공지능을 사용할까?

머신 러닝



불량 이미지와 정상 이미지(**data sets**)를 많이 보여주면, 머신러닝 모델은 두 이미지를 구분하는 특징을 학습(**learning algorithm**)해서 새로운 이미지가 들어왔을 때 불량인지 정상인지 판단 (**trained model**)

예시: 스팸 메일 분류 시스템

학습 알고리즘 역할은 어떤 메일이 스팸인지 아닌지 구분하는 방법을 데이터를 통해 찾아내도록 훈련/학습을 하게 된다. 일반적으로 많이 사용하는 알고리즘은 나이브 베이즈(Naive Bayes), **로지스틱 회귀(Logistic Regression)** 등

작동 방식

1. 알고리즘을 선택. (예: 로지스틱 회귀)
2. 수많은 과거 메일 데이터(데이터셋)를 입력함.
3. 알고리즘은 메일의 단어 빈도, 구두점, 발신자 정보 등을 분석하며, 어떤 특성이 '스팸'일 가능성을 높이는지에 대한 수학적 규칙을 계속해서 업데이트


참고: 로지스틱 회귀(Logistic Regression)

- 로지스틱 회귀의 목적은 입력된 데이터를 바탕으로 특정 사건이 발생할 확률을 계산하는 것
- 입력: 메일에 포함된 단어(예: '당첨', '광고', '무료'), 발신 주소 등
- 계산: 각 요소에 '가중치'를 곱해 점수를 합산.
- 출력: 최종적으로 이 메일이 스팸일 확률이 0에서 1 사이(0%~100%)의 값으로 주어짐

학습 과정 (Learning Process)은 알고리즘이 '수학적 규칙을 업데이트한다'

- **처음에는 감으로:** 처음엔 어떤 단어가 중요한지 몰라 가중치를 무작위로 둬
- **예측과 실제 비교:** "이건 스팸일 확률 80%야!"라고 예측했는데, 실제로는 정상 메일이었다면?
- **오차 수정:** '틀렸네? "당첨"이라는 단어에 너무 높은 점수를 줬나 보군.' 하며 가중치를 미세하게 조정
- **반복:** 수만 건의 데이터를 돌리며 이 과정을 반복하면, 어떤 단어가 진짜 스팸을 결정하는 핵심 지표인지 정교하게 파악.

로지스틱 회귀 '감으로 시작해 가중치를 맞춰가는 학습 과정'
 $y=ax+b$ 그래프와 시그모이드 곡선 변화 시각화



1. $y = ax + b$ 직선의 진짜 의미

직선은 '스팸과 정상을 나누는 기준선(경계선)'.

직선의 위쪽에 데이터가 있으면 AI는 "이건 스팸이다!"라고 판단.

직선의 아래쪽에 데이터가 있으면 AI는 "이건 정상이다!"라고 판단.

2. 가중치가 변한다는 것의 시각적 의미

라이브러리가 가중치 a 와 b 를 수정하면 그래프로 표현.


a (기울기)가 변하면: 직선이 제자리에서 회전. (어떤 단어에 더 민감하게 반응할지 결정)

b (절편)가 변하면: 직선이 통째로 위아래로 이동. (스팸이라고 판단하는 기준치를 높이거나 낮춤)

[초기] 직선이 가로로 누워 있음 ($a=0$, b =낮음). 모든 데이터를 '정상'으로 오해.

[학습 중] AI가 가중치 a 를 키워 직선을 세우기(회전) 시작. b 를 조절해 위로 올림.

[최적화] 직선이 두 데이터 집단 사이를 정확하게 가로지르는 위치에 멈춤.




1단계: INITIAL GUESS (초기 상태)현상: 데이터(주황색: 스팸, 파란색: 정상)와 무관하게 거의 평평한 회색 직선이 그려져 있음. 기울기 a 가 거의 0에 가깝고 절편 b 도 낮아 데이터를 전혀 구분하지 못함. 가중치: 무작위 초기값.


2단계: TRAINING (학습 중)현상: AI가 오차를 인지하고 가중치를 수정. 직선이 데이터 사이의 빈 공간을 향해 회전(기울기 a 증가)하고 동시에 위로 이동(절편 b 증가). 희미한 회색선들은 이전 단계의 위치를 보여주고 있음. 가중치: 데이터를 분류하기 위해 기울기와 절편 값을 계속 키워나가는 중.

3단계: OPTIMAL BOUNDARY (최종 모델)현상: 직선이 스팸 데이터와 정상 데이터 집단을 가장 정확하고 깨끗하게 가로지르는 황금 각도를 찾음. 이 최종 위치가 바로 우리가 찾던 완성된 Trained Model. 가중치: 최소 오차를 달성한 최적의 a 와 b 값에 수렴.

학습 단계(Iteration)'에 따라 기준선 변하는 '순서' 시각적 표현



학습 단계(Iteration)'에 따라 기준선 변하는 '순서' 시각적 표현



학습 단계(Iteration)에 따라 기준선 변하는 순서 고찰

1. '판단(0 또는 1)'과 '확률(0.1 ~ 0.9)'의 차이 그림에서 직선은 '결정 경계(Decision Boundary)'. 그림의 모습: 직선을 기준으로 위쪽은 스팸, 아래쪽은 정상. 실제 내부 계산: 직선 바로 근처에 있는 점들에 대해 AI는 "이건 51% 확률로 스팸이야"라고 아주 부정확하게 예측하고 있음. 반면 직선에서 멀리 떨어진 점들은 "이건 99.9% 확률로 스팸이야"라고 확신. 결론: 그림에서는 명확히 나뉜 것처럼 보이지만, 사실 직선 근처의 데이터들은 상당한 '오차 확률'을 갖고 있는 상태.

2. '훈련 데이터'에 너무 잘 맞춘 경우 (과적합의 위험) 두 번째 이미지부터 직선이 데이터를 완벽하게 보이는 이유는, AI가 준 데이터를 '달달 외웠기' 때문일 수 있다. 훈련(Training) 단계: AI는 주어진 데이터셋에서 오차를 0으로 만들기 위해 직선을 조정. 오차가 하나도 없는 '완벽한 선'처럼 보이기도 함. **진짜 문제:** 현재 데이터에만 너무 완벽하게 맞춘 선은 새로운 스팸 메일은 제대로 못 맞출 수도 있다. 이를 AI 용어로 '**과적합(Overfitting)**'.

3. 학습의 목표는 '오차의 최소화'이지 '오차 0'이 아님. 실제 데이터는 예시 떨어져 있지 않고 서로 겹쳐 있는 경우가 훨씬 많다. 만약 파란 점 하나가 주황색 집단 한가운데 섞여 있다면, 아무리 직선을 잘 그어도 오차는 발생. **AI의 선택:** 이때 AI는 그 점 하나를 포기하더라도, 전체적인 오차의 합(Loss)이 가장 적은 직선을 선택. **그림의 한계:** 설명용 그림에서는 원리를 보여주기 위해 데이터를 일부러 멀리 떨어뜨려 놓았기 때문에 오차가 없는 것처럼 보일 뿐, 실제 현장에서는 "**최대한 덜 틀리는 선(최적값)**"을 긋는 것이 목표.

$y = ax + b$ 에서 algorithm에서는 a, b 값을 찾아가는 것이고 trained model에서는 찾은 a, b 값을 이용하여 결과값을 내는 것

수학적으로 보면 알고리즘은 a 와 b 라는 미지수(가중치, 편향)를 찾아가는 과정이고, 모델은 그 미지수가 숫자로 확정된 결과물.

1. 학습 알고리즘 (Learning Algorithm)

이 단계에서 **a 와 b 는 정해지지 않은 변수**

목표: 수많은 데이터(x, y 쌍)를 넣어보며, 실제 정답 y 와 내가 계산한 y 사이의 오차가 가장 적어지는 최적의 a (가중치)와 b (편향)를 찾아내는 것.

행동: "지금 $a=1, b=0$ 으로 해보니까 틀렸네? 그럼 a 를 조금 키워볼까?" 하며 숫자를 계속 수정.

2. 학습된 모델 (Trained Model)

이 단계에서 **a 와 b 는 확정된 숫자**

상태: 학습이 끝나면 더 이상 a 와 b 를 수정하지 않음. 예를 들어 $a=0.8, b=0.2$ 라고 결정이 된 상태.

행동: 새로운 데이터(x)가 들어오면, 이미 정해진 숫자를 대입해 결과(y)를 바로 내놓음.
예: $y = 0.8x + 0.2$ 라는 공식에 새로운 x 만 넣으면 끝

a, b가 스팸 메일에서 하는 역할

x (데이터): '당첨'이라는 단어가 메일에 들어있는 횟수

a (가중치/Weight): '당첨'이라는 단어가 스팸 확률을 얼마나 높이는지 결정하는 수치 (예: a=5)

b (편향/Bias): 어떤 단어와 상관없이 기본적으로 스팸일 확률이 얼마나 깔려있는지 조절하는 수치 (예: b=-2)

y (결과값): 스팸일 가능성 점수

**알고리즘은 최적의 a와 b를 찾기 위한 학습 과정이고,
모델은 학습 끝에 a와 b값을 다 외워버린 정답지'.**

머신 러닝

LLM(Large Language Model, 거대 언어 모델)은 AI 기술 중 가장 거대하고
정교하게 '학습된 모델(Trained Model)' 완성판

ChatGPT나 Gemini 같은 LLM을 사용할 때, 이미 '학습이 끝난 모델'과 대화하고 있는 것

1. LLM도 결국 거대한 $y = ax + b$ 의 집합

LLM 내부에는 a (가중치)가 상상을 초월할 정도로 많이 들어있음

매개변수(Parameter): LLM에서 말하는 '70B(700억 개)', '175B(1,750억 개)'라는 숫자가 바로
모델이 학습을 통해 찾아낸 a, b 값들의 개수.

작동 원리: 문장의 앞 단어들이 x 로 들어오면, 수천억 개의 a 값들과 계산하여 다음에 올
가장 확률 높은 단어(y)를 출력.

2. LLM의 두 단계

LLM도 똑같이 '알고리즘 단계'와 '모델 단계'

① **사전 학습** (Pre-training: 알고리즘 단계)과정: 트랜스포머(Transformer)라는 복잡한
알고리즘을 사용하여 인터넷상의 방대한 텍스트 데이터를 읽음

목표: 수조 개의 문장을 보면서 단어들 사이의 관계(a 값들)를 스스로 조정.

결과: 이 과정이 끝나면 엄청난 지식을 가진 학습된 모델이 탄생.

② **추론 (Inference: 모델 단계)상태:** 우리가 질문을 던지는 단계.

작동: 모델은 이미 고정된 수천억 개의 가중치(a, b)를 사용하여, 질문에 대한 최적의
답변을 계산. 이때 모델은 더 이상 새로운 지식을 실시간으로 배우지 않고, 이미
학습한 가중치만 써서 답을 냄.

머신 러닝

머신러닝 핵심 GPU(그래픽 처리 장치): 인공지능의 심장

GPU는 '단순 계산'을 수천 개씩 동시에 처리하는 데 특화

1. CPU vs GPU: 수학천재 vs 대학원생 1,000명

CPU와 GPU의 차이를 살펴 보면

CPU (중앙 처리 장치): 복잡한 논리 구조를 처리하는 천재 수학자. 미분, 적분, 논리 판단 등 어려운 일을 하나씩 순서대로 아주 빠르게 처리.

GPU (그래픽 처리 장치): 아주 단순한 계산이 가능한 대학원생 1,000명. 한 명은 수학자보다 느리지만, 1,000명이 동시에 계산하면 단순 반복 작업은 더 효율적.

2. AI 모델은 왜 GPU를 효율적인가?

학습된 모델(Trained Model)의 본질을 살펴보자. 모델은 정해진 a, b 값에 x 를 대입해서 결과를 계산한다.

AI 계산 방식: $y = ax + b$ 같은 계산이 한두 개가 아니라, 수조 개가 얹힌 거대한 행렬(Matrix) 계산.


특징: 이 계산들은 서로 복잡하게 얹혀 있기보다, 독립적인 곱셈과 덧셈이 무수히 반복되는 형태.

GPU의 활약: 1번 대학원생은 1번 $ax+b$ 계산하고 2번은 2번하고 ... 방식으로 병렬(Parallel)로 한꺼번에 처리함.

→ 학습 알고리즘에서는 최적 a, b 값을 찾기 위해 수조 번의 시행착오 계산을 수행 (엄청난 GPU 필요)하고 학습된 모델에서는 고정된 a, b 값으로 결과를 계산하기 위해 수천 개의 계산을 동시에 수행: **효율적인 GPU 필요**

머신 러닝

데이터의 흐름과 기계 장치



머신 러닝

데이터의 흐름과 기계 장치



SSD/HDD (원재료 야적장): 공장 밖, 아주 넓은 터에 원재료(데이터)가 산더미처럼 쌓여 있음.

공간은 넓지만, 공장 안으로 가져오려면 트럭을 타고 한참 가야 해서 가장 느림.

DRAM (공장 내부 창고): 공장 건물 안에 있는 주 창고. 야적장에서 가져온 재료들을 박스에 담아 잘 정리해 두고 있음. 기계(GPU)와는 거리가 좀 있지만, 야적장보다는 훨씬 빠르고 전송량도 많음.



HBM (기계 옆 선반): 기계(GPU) 바로 옆에 붙어 있는 전용 선반. 창고(DRAM)에서 가져온 재료들을 손만 뻗으면 닿을 거리에 엄청나게 쌓아 두고 있음. 속도가 창고보다 수십 배 빠르며, 동시에 엄청난 양의 재료를 기계에 공급할 수 있음.

GPU (물건 만드는 기계): 공장의 핵심인 최첨단 자동화 기계. HBM 선반에서 재료를 받아 눈 깜짝할 사이에 물건(연산 결과)을 만들어 낼 수 있음.


딥러닝

딥러닝(Deep Learning)은 인간의 뇌 구조를 모방한 인공신경망을 통해 컴퓨터가 스스로 학습하는 기술이다. **머신러닝의 한 종류**

생물학적 신경망 vs. 인공 신경망 (Biological Neural Network vs. Artificial Neural Network)



인공 신경망의 층 구조 (Layered Structure of an Artificial Neural Network)



딥러닝

딥러닝에서 'Deep(깊다)' 표현을 쓰는 이유는 데이터가 정답을 찾아가기 위해 사용하는 **단계(층)**가 아주 많기 때문

생물학적 뉴런이 전기 신호를 받아 일정 수치를 넘기면 다음 뉴런으로 신호를 보내듯, 인공신경망에서도 유사한 과정이 일어난다.

뉴런 (Node/Unit): 데이터를 처리하는 최소 단위

시냅스 (Weight/가중치): 뉴런과 뉴런 사이의 연결 강도. 딥러닝 학습의 핵심은 바로 이 '시냅스의 두께(가중치)'를 최적화(Optimization)하여 정답에 가까운 신호(값)만 전달.

뉴런들은 횡적으로 정렬되어 하나의 층(Layer)을 형성하고, 이 층들이 종적으로 쌓여 전체 신경망을 구성

입력층 (Input Layer): 외부 데이터를 처음 받아들이는 뉴런. (예: 이미지의 픽셀 값)

은닉층 (Hidden Layer): 입력층과 출력층 사이의 층들. 여기서 실제 학습을 진행. 첫 번째 은닉층은 선이나 점 같은 단순한 특징을 찾고, 뒤로 갈수록 원이나 사각형, 더 나아가 코나 눈 같은 복잡한 형상을 인식.

출력층 (Output Layer): 모든 계산을 마친 후 최종 결과를 내보낸다. (예: "이 사진은 98% 확률로 고양이입니다.")

딥러닝

딥러닝에서 가장 유명한 예시인 '고양이 인식'을 통해 입력층, 은닉층, 출력층 역할

1. 입력층 (Input Layer): "픽셀 숫자의 나열"

우리는 고양이 이미지를 보지만, 컴퓨터는 수많은 숫자(픽셀 값)로 인식.

입력 데이터: 100x100 크기 이미지라며 총 10,000개의 픽셀 정보(색상, 밝기 등)가 입력층의 뉴런 하나하나에 입력됨.

역할: 픽셀의 밝기(0~255) 등의 수치 데이터를 신경망 내부로 전달하는 첫 번째 관문.

2. 은닉층 (Hidden Layer): "특징 조립하기"

고양이 인식의 핵심은 은닉층이 '깊어질수록(Deep)' 더 복잡한 특징을 찾아냄

앞부분 은닉층 (Low-level): 픽셀들의 수치를 조합 선/점 같은 기초적인 시각 특징을 추출.

중간부분 은닉층 (Mid-level): 선들을 조합해 귀, 눈, 코 같은 부분적인 모양을 식별.

뒷부분 은닉층 (High-level): 부분 모양들을 종합하여 고양이의 전체적인 형체나 고유한 패턴을 고차원적으로 파악.

3. 출력층 (Output Layer): "최종 확률 결과 출력"


각 카테고리(고양이, 강아지 등)별로 점수를 계산한 뒤, 이를 확률값으로 변환하여 최종 결론을 내림

결과값: 은닉층을 거치며 계산된 신호들이 모여 각 카테고리별 최종 점수를 산출.

최종 판단: 고양이 뉴런 확률값이 가장 높으면(예: 0.98), 98% 확률로 고양이라고 최종 결과를 출력.

딥러닝

딥러닝에서 가장 유명한 예시인 '고양이 인식'을 통해 입력층, 은닉층, 출력층 역할



인공지능(AI) 학습 방식

지도 학습 (Supervised Learning): 정답지가 있는 공부

문제와 정답을 함께 주고 학습시키는 방식. 데이터에 '이것은 고양이 사진이다', '이것은 강아지 사진이다'라는 이름표(Label)가 붙어 있다.

학습 방식: 문제(데이터)와 정답(라벨)을 맞히면서 규칙을 찾음.

목표: 새로운 데이터를 봤을 때 정답을 맞히는 것.

- 현재 인공지능 산업에서 가장 많이 사용되고, 가장 돈을 잘 벌어들여 주며, 가장 성능이 검증된 핵심 기술

- 우리가 실생활에서 편리하다고 느끼는 대부분의 AI 서비스는 지도 학습 기반

정확도: 정답(Label)이 명확하기 때문에 비지도 학습보다 훨씬 정확한 결과값

신뢰성: 기업 입장에서 '정답'이 있는 데이터를 학습시킨 AI는 예상 범위를 벗어나는 행동을 덜 하기 때문에 훨씬 안전

산업적 가치: 불량품 판정, 질병 진단, 신용 점수 계산 등 비즈니스에서 중요한 결정은 대부분 '정답'이 필요한 문제들.

최근 ChatGPT 같은 생성형 AI(거대언어모델)가 큰 인기를 끌면서, 지도 학습이 뒤쳐진 것처럼 보일 수 있다. **하지만,**

- ChatGPT 같은 모델도 처음엔 방대한 데이터를 스스로 읽지만(비지도 학습), 마지막에 '좋은 답변'에 더 높은 점수를 주는 인간 피드백 기반 학습(RLHF) 과정이 바로 지도 학습의 변형

- 지도 학습의 유일한 단점은 일일이 정답지를 만들어야 한다는 비용과 시간 문제. 그래서 데이터가 너무 많을 때는 비지도 학습을 먼저 섞어서 사용한다.

인공지능(AI) 학습 방식

비지도 학습 (Unsupervised Learning): 정답 없이 스스로 특징 찾기

정답지 없이 데이터만 주고 학습시키는 방식. 인공지능이 스스로 데이터 사이 유사점이나 차이점을 분석해서 비슷한 것끼리 묶음.

학습 방식: 데이터의 패턴이나 구조를 스스로 발견.

목표: 데이터 속에 숨겨진 특징을 찾아 그룹화(Clustering)하는 것.

- 데이터 자체 패턴과 구조를 스스로 파악하는 학습법. 데이터에 일일이 이름표(Label)를 붙일 필요가 없다는 점이 가장 큰 매력

데이터 준비 비용 절감: 사람이 직접 정답지(라벨)를 만들 필요가 없어, 막대한 양의 raw 데이터를 그대로 사용.

미처 몰랐던 패턴 발견: 사람이 미리 정의한 카테고리에 갇히지 않고, AI가 데이터 사이의 숨겨진 상관관계나 새로운 그룹을 발견.

데이터 전처리 및 압축: 복잡하고 차원이 높은 데이터를 핵심 특징만 남기고 단순화하여, 다른 AI 모델의 학습 효율을 제고.

비지도 학습은 주로 비슷한 것끼리 묶기(Clustering)와 이상한 것 찾아내기(Anomaly Detection)에 탁월한 성능

- 고객 세분화 및 타겟 마케팅
- 이상 거래 탐지 (FDS)
- 유전자 분석 및 의료 진단
- 생성형 AI의 기초 학습 (Pre-training)

인공지능(AI) 학습 방식

강화 학습 (Reinforcement Learning): 시행착오를 통한 실전 학습

정답 대신 보상(Reward)을 주는 방식. 잘하면 상을 주고, 못하면 벌을 주면서 가장 높은 점수를 얻는 방법을 스스로 터득.

학습 방식: 수많은 행동을 시도해 보고 보상을 많이 받는 방향으로 진화.

목표: 보상을 최대화하는 최적의 전략을 찾는 것.

- 정답이나 데이터의 패턴을 찾는 것을 넘어, 어떤 행동을 해야 가장 큰 이득을 얻을까를 고민하는 의사 결정 중심의 학습법.

정답이 없는 문제 해결: 사람이 일일이 정답을 알려줄 수 없는 복잡한 환경에서도 AI 스스로 시행착오를 겪으며 최적의 경로를 찾아낸다.

창의적인 전략 발견: 인간이 생각하지 못한 파격적인 수나 효율적인 방법을 찾아낼 수 있다. (예: 알파고가 바둑에서 보여준 변칙수)


동적인 환경 적응: 실시간으로 변하는 상황에 맞춰 보상을 최대화하도록 계속해서 행동을 수정하고 발전시킨다.

강화 학습은 주로 순차적인 선택이 중요하고, 최종 목표(보상)가 뚜렷한 분야에서 강력한 힘을 발휘한다.


- 자율주행 및 로봇틱스
- 게임 및 e스포츠
- 금융 및 에너지 최적화
- 추천 시스템 및 광고

인공지능(AI) 학습 방식


지도 학습
(Supervised Learning)



비지도 학습
(Unsupervised Learning):



강화 학습
(Reinforcement Learning):



인공지능(AI) 학습 방식

인공지능의 세 가지 학습법(지도, 비지도, 강화 학습)은 각각 독립적으로 쓰이기보다, 요리처럼 적절한 순서와 비율로 섞었을 때 최고의 성능을 발휘

전문 자산관리사처럼 사고하는 AI를 설계

1단계: 비지도 학습 (세상의 흐름 읽기)

먼저 정답 없이 방대한 양의 기초 데이터를 AI에게 입력.

- **학습 데이터:** 지난 30년간의 전 세계 뉴스 기사, 경제 지표(금리, 환율, GDP), 기업 공시 자료, SNS 투자 포럼 글 등.
- **AI가 하는 일:** "금리가 오르면 보통 기술주 주가가 떨어지는 경향이 있네?", "전쟁 뉴스가 나오면 금값이 오르는구나" 같은 **경제의 상관관계와 패턴**을 스스로 찾아낸다.
- **결과:** 경제 용어의 의미와 시장의 거시적인 흐름을 이해하는 '박학다식한 기초 모델'이 탄생다.

2단계: 지도 학습 (전문가의 판단 배우기)

기초를 닦은 AI에게 전문가가 작성한 '정답지'를 주어 정교하게 다듬는다.

- **학습 데이터:** "이런 재무제표를 가진 기업은 '저평가' 상태이다", "이 차트 패턴은 '매수 신호'이다"라고 전문가가 라벨링(이름표)을 붙인 데이터.
- **AI가 하는 일:** 과거 특정 시점의 데이터를 보고 "이때 주식을 사아야 했나?"라는 문제에 대해 전문가의 판단(정답)과 비교하며 **정확한 분석 규칙**을 배운다.
- **결과:** 재무제표를 분석하고 리포트를 요약할 줄 아는 '똑똑한 애널리스트 AI'가 된다.

3단계: 강화 학습 (실전 수익률 최적화)

마지막으로 가상 매매 환경(시뮬레이션)에 AI를 투입해 실전 감각을 키운다.

- **학습 방식:** AI가 가상의 돈으로 주식을 사고팔게 한다. 수익이 나면 보상(+)을 주고, 손실이 나면 벌(-)을 준다.
- **AI가 하는 일:** 처음에는 미로 이미지의 앞부분처럼 무작정 사고팔며 실수(x)도 하지만, 시간이 지날수록 리스크를 줄이면서 수익을 극대화하는 필승 전략을 찾아낸다.
- **결과:** 시장의 변화에 유연하게 대응하며 실질적인 수익을 추구하는 '베테랑 펀드매니저 AI'로 거듭난다.